Construcción de un Árbol de Decisión

ANÁLISIS DE DATOS Y GANANCIA DE INFORMACIÓN EN TELECOMUNICACIONES

Enunciado del Caso: Una empresa de telecomunicaciones quiere predecir si un cliente aceptará una oferta de plan de datos móviles. Para ello, se dispone de un conjunto de datos con información de 10 clientes, incluyendo los siguientes atributos:

- **Edad:** en años
- **Uso de datos:** nivel de uso mensual (en GB)
- **Tiene línea fija:** Sí / No
- **Aceptó la oferta:** Sí / No (Variable Objetivo)

Conjunto de Datos de Muestra

ID	Edad	Uso de datos (GB)	Tiene línea fija	Aceptó oferta
1	24	2.5	No	No
2	38	6.0	Sí	Sí
3	29	3.0	No	No
4	45	8.0	Sí	Sí
5	52	7.5	Sí	Sí
6	33	4.0	No	No
7	41	5.5	Sí	Sí
8	27	2.0	No	No
9	36	6.5	Sí	Sí
10	31	3.5	No	No

1. Cálculo de la Entropía del Conjunto Original

El conjunto cuenta con un total de 10 clientes, donde la variable objetivo es **Aceptó oferta** (Sí / No).

- **Casos totales (S):** 10
- **Aceptaron (Sí):** 5 clientes (IDs 2, 4, 5, 7, 9)
- **No aceptaron (No):** 5 clientes (IDs 1, 3, 6, 8, 10)

Al estar la muestra dividida exactamente a la mitad, la incertidumbre o entropía inicial es máxima:

$$H(S) = -\left(\frac{5}{10}\log_2\left(\frac{5}{10}\right) + \frac{5}{10}\log_2\left(\frac{5}{10}\right)\right) = 1.0 \text{ bits}$$

2. Evaluación de la Ganancia de Información para los Atributos

Para determinar qué variable organiza mejor los datos, calculamos la ganancia de información de cada atributo:

A. Atributo: Edad (rangos)

- **Joven (≤30):** 3 casos; 0 aceptaron, 3 rechazaron. (Entropía = 0)
- **Adulto (31–50):** 6 casos; 4 aceptaron, 2 rechazaron. (Entropía ≈ 0.918)
- **Mayor (>50):** 1 caso; 1 aceptó, 0 rechazaron. (Entropía = 0)
- **Ganancia de Información:** $1.0 - ({}^{3}/_{10}(0) + {}^{6}/_{10}(0.918) + {}^{1}/_{10}(0)) = 0.449 \text{ bits}$

B. Atributo: Tiene línea fija

- **Sí:** 5 casos; los 5 aceptaron la oferta. (Entropía = 0)
- **No:** 5 casos; los 5 rechazaron la oferta. (Entropía = 0)
- **Ganancia de Información:** $1.0 - ({}^{5}/_{10}(0) + {}^{5}/_{10}(0)) = 1.0 \text{ bit}$

C. Atributo: Uso de datos (rangos)

- **Bajo (≤3 GB):** 3 casos; 0 aceptaron, 3 rechazaron. (Entropía = 0)
- **Medio (3.1–6 GB):** 4 casos; 2 aceptaron, 2 rechazaron. (Entropía = 1.0)
- **Alto (>6 GB):** 3 casos; los 3 aceptaron. (Entropía = 0)
- **Ganancia de Información:** $1.0 - ({}^{3}/_{10}(0) + {}^{4}/_{10}(1.0) + {}^{3}/_{10}(0)) = 0.6 \text{ bits}$

3. Construcción del Árbol de Decisión

Dado que el atributo **Tiene línea fija** presenta la ganancia de información más alta (1.0 bit), se establece como el nodo raíz del árbol. Al dividir la muestra por este criterio, se obtienen subconjuntos completamente homogéneos (entropía cero), resolviéndose en su primer nivel:

```
[¿Tiene línea fija?] ├── Sí ──> [Predicción: Acepta la oferta (Sí)] └── No ──>
[Predicción: No acepta la oferta (No)]
```

4. Conclusión

- **Mejor atributo inicial:** El atributo óptimo es **Tiene línea fija**, ya que maximiza la ganancia de información (1.0 bit), logrando una separación perfecta de las clases sin requerir ramificaciones adicionales.
- **Aplicación práctica:** Para predecir si un cliente aceptará la oferta, solo es necesario verificar si posee línea fija: si es afirmativo, predice que aceptará; en caso contrario, predice que rechazará.